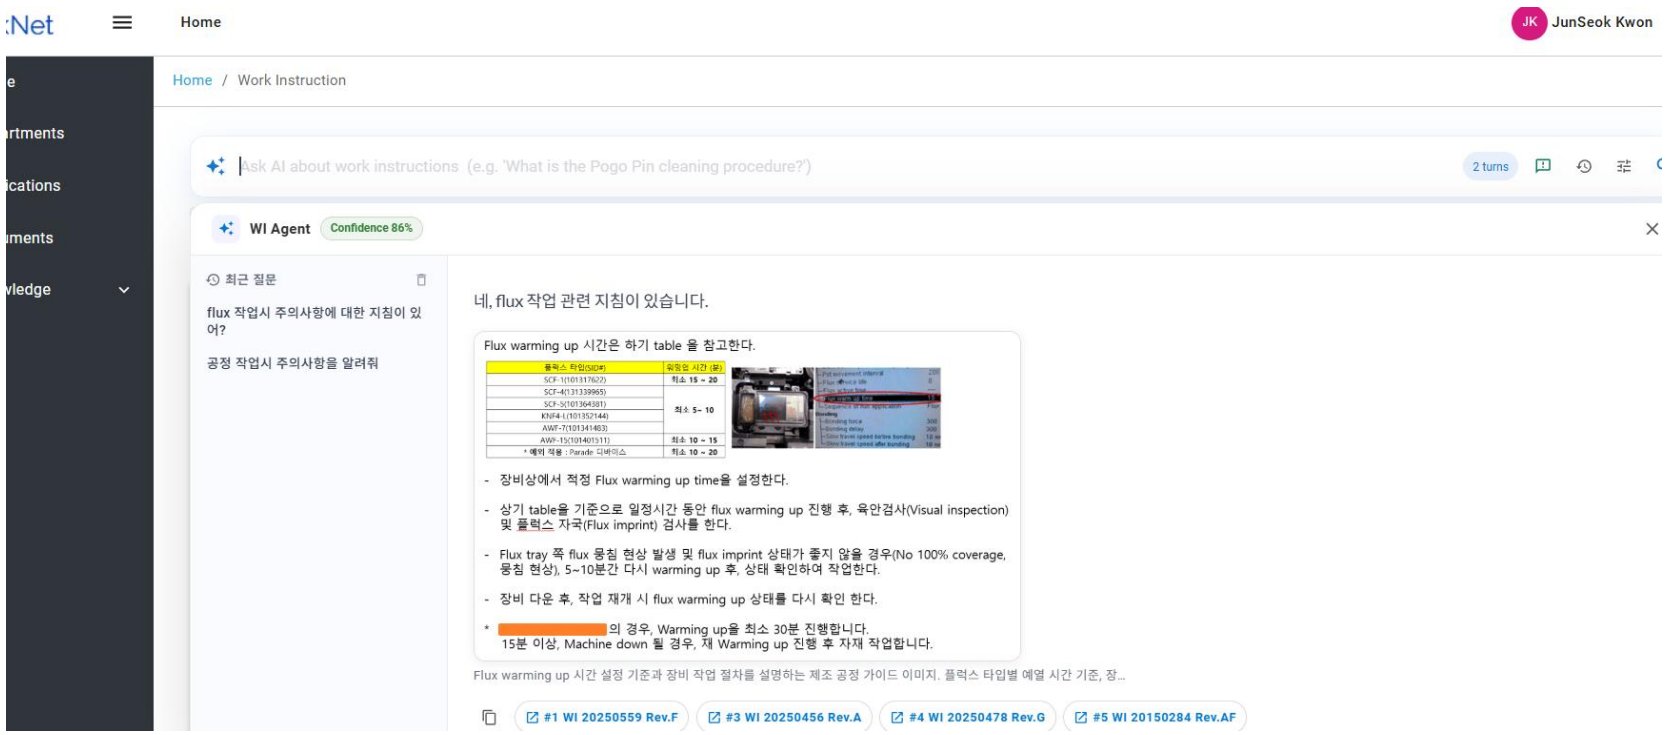
Amkor WI Chatbot

제조 작업표준서
이미지 연계 RAG 챗봇

질문에서 출처까지,
작업 근거를 연결하다.

문서 수집 · 검색 · 답변 API
이미지 제공 · 운영 구성

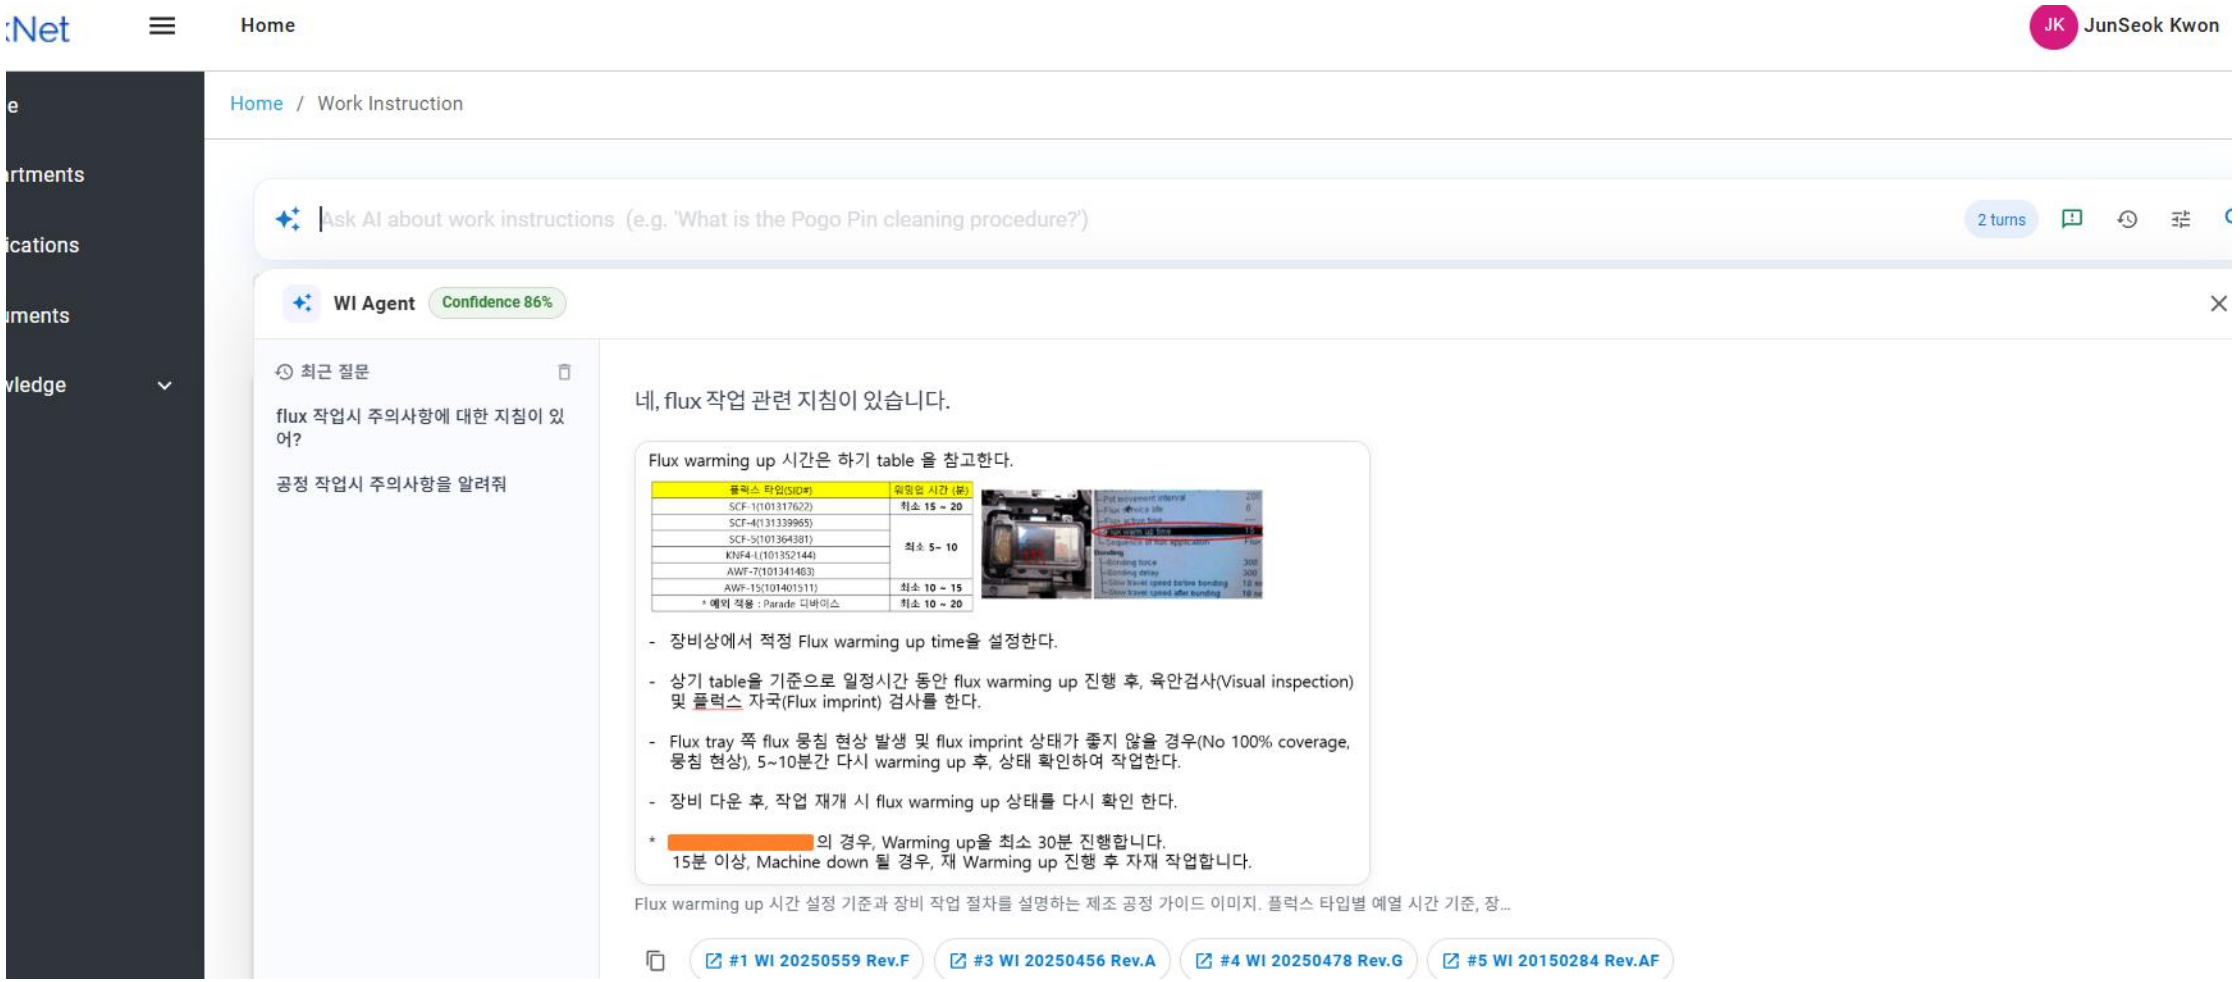


문서를 찾는 것과 작업 근거를 찾는 것은 다르다

작업표준서는 텍스트, 표, 설비 화면과 사진이 결합된 비정형 자료다.

업무의 어려움	구현한 접근
형식이 다른 파일을 개별 확인	**Office·PDF를 공통 JSONL로 변환**
텍스트만으로 작업 이미지를 이해하기 어려움	**VLM 이미지 설명을 별도로 검색**
답변의 원문과 개정 정보를 확인하기 어려움	**답변에 이미지·WI 출처를 함께 제공**

질문 한 번으로, 작업 이미지와 WI 출처까지



제공된 포털 결과 화면 | Confidence 86%는 검색 점수 기반 보조 지표이며 정답률이 아님

수집과 응답을 분리한 데이터 흐름

수집 · 인덱싱

WI 문서
파일 / URL

›

파싱 · 청킹
LlamaParse + 메타데이터

›

OneLake
JSONL 저장

›

인덱싱
정규화 + 배치 업로드

›

AI Search
텍스트 / 이미지 설명

이미지 분기: Office 이미지 추출 → VLM 설명 생성 → JSONL에 연결 / 원본 이미지는 Blob 저장

질의응답

사용자 질문
FastAPI + 선택적 Redis

›

질의 확장
이전 질문 반영

›

AI Search
문서와 이미지 조회

›

LLM
문서 근거 기반 답변

›

응답
답변 + 이미지 + 출처

이미지 바이너리는 백엔드 프록시를 통해 Blob Storage에서 제공

문서 구조를 살리고, 검색 메타데이터를 남기다

01

다운로드·파싱

Office·PDF·ZIP 입력
빈 파일·로그인 HTML 거부
파일 시그니처로 형식 추론

02

구조 기반 청킹

표: 행 묶음 + 헤더 반복
절차: 번호 섹션 + 중첩 문맥
슬라이드: 인식 단위 유지

03

업무 메타데이터

문서 ID · WI 번호 · 개정
부서 · 고객사 · 작업 구분
출처 파일 · 이미지 참조

기본 청킹 설정 2,000자 / 중첩 150자 · 구조 보존 경로에서는 초과 가능

이미지를 설명으로 바꾸어 검색에 연결하다

이미지 추출
표 · 사진 · 설비 화면

VLM 설명
한국어 의미 설명 생성

별도 인덱스
이미지 단위 레코드

관련성 선별
WI 참조 + 질의 관련성

검색 시점

문서 검색으로 WI 번호·개정 참조 확보
이미지 검색 점수와 설명의 관련성 평가
후보가 없으면 청크의 이미지 정보 활용

응답 시점

관련 이미지 최대 5개
JSON 응답은 단락 사이 배치 가능
원본은 Blob 프록시로 제공

이미지 벡터 직접 검색이 아닌, VLM이 생성한 설명을 활용한 검색 구조

질의 확장 → 결과 결합 → 근거 중심 컨텍스트

이전 질문을 반영한 후보 검색을 RRF로 결합하고, 중요 문서를 컨텍스트 앞뒤에 배치

검색 깊이	최대 질의 수	Top-K / 병합 상한	컨텍스트 상한
fast	1	2	2
standard	**2**	**5**	**5**
deep	4	10	8

근거가 약하면 응답 제한

구체적 사실 뒤에 [출처N] 표시

실제 질의 수는 중복 제거 후 달라질 수 있음. 검색 개선 폭과 정답률은 별도 측정 전.

질문부터 후속 대화까지 연결하는 API

응답 인터페이스

POST /api/wi/ask

JSON: 답변 · 출처 · 이미지 · confidence

POST /api/wi/ask/stream

SSE: 토큰 이벤트 + 완료 메타데이터

대화와 표현

응답 모드

precise / standard / summary

Redis 사용자별 이력

기본 TTL 30분 / 최대 40개 발화

React 데모는 JSON API 사용. JSON과 SSE의 이미지 배치·후처리는 현재 동일하지 않음.

실제 연동 문제를 처리 가능한 단위로 나누다

01 문서 대신 로그인 HTML

빈 응답·HTML 검사와 파일 시그니처 확인

다운로드 실패와 파싱 실패를 구분

02 저장소와 인덱스의 스키마 차이

wi_id 매핑, ID·고객사 타입 정규화, 허용 필드 제한

업로드 전에 데이터 계약을 정리

03 대용량 배치의 요청 크기 초과

배치를 재귀 분할하고 성공 건수·실패 키 집계

부분 실패를 식별하고 재처리 대상 확인

적재 이후의 동기화·배포·관측까지 구성

동기화

Fabric 증분 처리

수정 시각 + 업로드 레지스트리
신규·변경·이전 실패 파일 선택
전체 재업로드 옵션

배포

GitHub Actions

릴리스 PR 병합 후 테스트·빌드
원격 백업·전송·서비스 재시작
Linux / Gunicorn / Nginx

관측

오류와 추적 정보

처리 단계·error_id·실패 키
검색 시간·질의 수·출처 수
선택적 OpenTelemetry

구현된 구성과 실제 운영 성과는 구분

스케줄 등록·배포 성공 이력은 미검증. CLI·노트북의 스키마 통합 검증이 필요함.

로그와 테스트로 확인한 결과

88,996

텍스트 청크 업로드 성공

88,996 / 88,996건

226,586

이미지 검색 레코드 업로드 성공

226,586 / 226,586건

19

기존 단위 테스트 통과

파싱·검색 관련 2개 테스트 파일

해석 범위

업로드 수치는 저장된 개별 실행 로그. 원본 파일 수·현재 인덱스 수와는 다름.
테스트는 외부 API 모킹 기반. 실제 클라우드 연동·정답률·처리량 검증은 아님.
별도 텍스트 실행에는 88,997건 중 1건 실패 기록도 존재.

답변 생성보다 중요한 것은, 확인 가능한 근거

문서 구조를 보존하고, 이미지와 출처를 연결하며, 실패를 추적 가능하게 만든다.

현재 구현

수집부터 검색·응답까지 연결
이미지 설명 기반 검색
WI 번호·개정을 통한 근거 추적
업로드 로그와 단위 테스트 확보

다음 검증

대표 질문 세트로 검색·답변 평가
응답시간 p50·p95 및 비용 측정
삭제·개정·인덱스 스키마 통합
권한 검증과 JSON·SSE 일관성

기술 기반: FastAPI · Fabric OneLake · Azure AI Search · Azure OpenAI · Blob · Redis · React